

Subject: CS336 Assignment 1, Linear Module

Date: from 2026/7/24 to 2026/7/25

Contents

Linear Module	1
----------------------	----------

Linear Module

数学定义 vs. 工程现实

1. **数学视角**: $y = Wx$. 数学教科书里习惯把输入 x 看作列向量:
 - W 的维度是 $[\text{out}, \text{in}]$;
 - x 的维度是 $[\text{in}, 1]$;
 - 结果 y 是 $[\text{out}, 1]$.
2. **PyTorch 视角**: $y = xW^T$. 在计算机内存中数据按行主序 (row-major) 存储; 为了高效处理 Batch 数据, 输入 x 被组织为行向量:
 - 输入 x 形状: $[\text{Batch}, \text{in_features}]$;
 - 权重 W 形状: $[\text{out_features}, \text{in_features}]$;
 - 计算逻辑: 为了让维度匹配, 需要对 W 转置, 执行 $x @ W.T$.

	输入	权重	输出
数学视角	$[\text{in}, 1]$	$[\text{out}, \text{in}]$	$[\text{out}, 1]$
PyTorch 视角	$[\text{Batch}, \text{in}]$	$[\text{out}, \text{in}]$	$[\text{Batch}, \text{out}]$

权重初始化: Xavier 的思想

Linear 层对初始值极其敏感: 如果初始值太大, 输出会瞬间爆炸; 如果太小, 信号会迅速衰减. 因此这里实现截断正态分布初始化 (Truncated Normal Initialization).

- 标准差. $\sigma = \sqrt{\frac{2}{d_{in} + d_{out}}}$, 即 Xavier 的尺度;
- 原理. 保持层与层之间输出方差的一致性, 确保信号能传到深层;
- 截断范围. $[-3\sigma, 3\sigma]$.

为什么要截断? 剔除正态分布“长尾”处的极端异常值, 防止模型在第一步训练时就因为某个随机数太大而崩溃 (NaN).

```
std = math.sqrt(2.0 / (d_in + d_out))
bound = 3.0 * std
nn.init.trunc_normal_(self.weight, mean=0.0,
                       std=std, a=-bound, b=bound)
```