

Subject: CS336 Assignment 1, Transformer Module

Date: from 2026/7/26 to 2026/7/31

Contents

Transformer Module	1
RoPE 旋转位置编码	1
残差连接	3

Transformer Module

缩放因子 $\sqrt{d_k}$ 的意义

公式中除以 $\sqrt{d_k}$ 是为了解决梯度消失问题。

- **现象.** 随着维度 d_k 增大, 点积的方差会变得很大, 导致 Scores 中出现极大的数值 (如 100);
- **后果.** Softmax 函数在输入值很大时, 其导数 (梯度) 趋近于 0, 进入饱和区;
- **解决方案.** 通过除以 $\sqrt{d_k}$, 把分数的分布拉回到 0 附近, 确保信号在传输过程中既不过载也不消失, 让模型能够通过梯度下降进行学习。

RoPE 旋转位置编码

核心思想

传统方案 (BERT / GPT-2) 的绝对位置编码是把位置向量直接加在 Embedding 上. RoPE 的创新点在于: 通过旋转矩阵改变 Query (q) 和 Key (k) 的方向, 把位置信息编码进点积运算中。

成对旋转 (Pairwise Rotation). RoPE 把 d_k 维向量看作 $d_k/2$ 个 2D 平面上的点; 对于位置 i 的向量, 对它的每一对元素做旋转. 对应的 2D 旋转矩阵为

$$R_k^i = \begin{bmatrix} \cos \theta_{i,k} & -\sin \theta_{i,k} \\ \sin \theta_{i,k} & \cos \theta_{i,k} \end{bmatrix}$$

它把一个 2D 向量旋转 θ 角度. 最终的全局旋转矩阵 R^i 就是由这些 2×2 小矩阵构成的分块对角矩阵。

角度 $\theta_{i,k}$ 的计算

旋转角度由位置和维度共同决定:

$$\theta_{i,k} = \frac{i}{\Theta^{(2k-2)/d}}$$

其中:

- i (Position): Token 在序列中的索引;
- Θ (Theta): 常数基数, 通常取 10000;
- k : 不同维度对应不同的旋转频率, 取值范围为 $[1, d/2]$.

i 与 k 的坐标系

可以把 RoPE 想象成一个二维坐标系: i 代表纵向 (哪一个词), k 代表横向 (哪一个特征维度)。

i : Token 在序列中的位置

- **含义.** 当前处理的是第几个词;
- **作用.** 决定旋转的基本倍数; 位置越靠后 i 越大, 旋转角度成倍增加;

- 举例. 句子“我爱吃苹果”：“我” $i = 0$ ，“爱” $i = 1$ ，“吃” $i = 2$ ，“苹果” $i = 3$.

k : 维度对的索引

- 含义. 当前处理的是向量中的哪一对维度;
- 背景. RoPE 把 d 维向量拆成 $d/2$ 个两两一对的平面, k 的取值范围是 1 到 $d/2$;
- 作用. 决定旋转的频率 (速度): k 越小旋转越快, k 越大旋转越慢;
- 举例. 假设词向量为 128 维 ($d = 128$): 第 0,1 维组成第 1 对平面 ($k = 1$), 第 2,3 维组成第 2 对平面 ($k = 2$), 依次类推.

工程实现 (向量化)

在数学上, RoPE 描述为一个巨大的分块对角矩阵; 但在工程实践中, 为了压榨 CPU 的性能, 我们绝对不会构建这个稀疏矩阵, 而是利用张量广播和成对变换来实现.

$$R_{\Theta, m}^d x = \begin{pmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \\ \vdots \\ x_{d-1} \\ x_d \end{pmatrix} \otimes \begin{pmatrix} \cos m\theta_1 \\ \cos m\theta_1 \\ \cos m\theta_2 \\ \cos m\theta_2 \\ \vdots \\ \cos m\theta_{d/2} \\ \cos m\theta_{d/2} \end{pmatrix} + \begin{pmatrix} -x_2 \\ x_1 \\ -x_4 \\ x_3 \\ \vdots \\ -x_d \\ x_{d-1} \end{pmatrix} \otimes \begin{pmatrix} \sin m\theta_1 \\ \sin m\theta_1 \\ \sin m\theta_2 \\ \sin m\theta_2 \\ \vdots \\ \sin m\theta_{d/2} \\ \sin m\theta_{d/2} \end{pmatrix}$$

为了实现上式的旋转, 代码中对向量做“偶数位”和“奇数位”的切片:

- $x_{\text{even}} = [x_0, x_2, x_4, \dots]$, 即偶数索引;
- $x_{\text{odd}} = [x_1, x_3, x_5, \dots]$, 即奇数索引.

旋转计算 (二维旋转矩阵展开):

$$\begin{cases} x'_{\text{even}} = x_{\text{even}} \cos \theta - x_{\text{odd}} \sin \theta \\ x'_{\text{odd}} = x_{\text{odd}} \cos \theta + x_{\text{even}} \sin \theta \end{cases}$$

其中 $\theta = m \cdot w_k$, m 是 token 的绝对位置, w_k 是第 k 组维度的旋转角速度.

PyTorch 广播机制

1. 什么是广播? 当你对两个形状 (Shape) 不一样的张量做算术运算 (加、减、乘、除) 时, PyTorch 会在后台自动、循环地拉伸较小的张量, 使其形状与较大的张量对齐.

2. 广播的两大核心法则 (右对齐原则) 判断两个张量能否广播时, 先把它们的 Shape 右对齐, 然后从右往左看, 每一位必须满足以下条件之一:

1. 相等: 该维度的数值完全一样;
2. 其中一个为 1: 数值为 1 的那个维度会被自动“影分身”复制, 直到和对方一样大;
3. 其中一个缺失: 如果左边没位了, 就自动补 1, 然后继续应用规则 2.

3. RoPE 实现中的经典场景 代码中经常遇到:

- x (Query / Key): 形状 [B, H, S, D] (Batch, Head, Seq, Dim);

- $\cos/\sin$ 缓存：形状 $[S, D]$.

把 $[S, D]$ 在左边补两个维度变成 $[1, 1, S, D]$ ，再和 $[B, H, S, D]$ 广播， B 、 H 维度会自动复制，无需显式 `expand`.

残差连接

残差结构




Figure 1: A pre-norm Transformer block.

残差连接的数学表达式：

$$y = x + f(x)$$

即把子层输出 $f(x)$ 与原始输入 x 相加，为信号提供一条不经过任何变换的“捷径”（short-cut）。

梯度消失与网络退化

1. 梯度消失 深层网络反向传播时梯度逐层衰减，残差的主路径让梯度可以直接回流到底层。

2. 网络退化

a. 现象描述 模型深度增加，训练集准确率先饱和，之后训练集性能也下降. 要和过拟合区分开：

- 过拟合：训练集效果好、测试集差；
- 网络退化：连训练集都练不好.

b. 本质原因

- 信息磨损. 信号每经过一层线性变换加非线性激活，都会丢失部分原始信息；层数堆叠后原始特征被破坏；
- 恒等映射陷阱. 深层网络直接学习恒等映射 $H(x) = x$ 非常难，权重初始接近 0，网

络容易把输入抹平，做不到“原样传递”。

c. 残差连接怎么解决：把 $y = H(x)$ 改成 $y = F(x) + x$

- 赋予网络“不做功”的能力。当该层不需要做变换时，优化器只需要把残差分支 $F(x)$ 的权重趋近 0： $y = 0 + x = x$ ，直接实现恒等映射；配合 Weight Decay 倾向把多余权重压到 0，保留原始输入成为默认选择；
- 信息逐层递增（大底座 + 小补丁）。输入 x 直接作为保底底座，分支 $F(x)$ 只学习微小增量（残差），不需要每层重新构造全部特征；信息沿 shortcut 通路保留，深层不会把原始信息磨没，特征持续精炼。

PreNorm vs PostNorm

Transformer 的归一化层有两种摆放方式：

1. Post-norm（原始 Transformer 论文）

$$\text{Norm}(x + \text{Sublayer}(x))$$

- 流程. 先残差相加 $x + \text{Sublayer}(x)$ ，相加完再做归一化；
- 缺点. Norm 落在残差主路径上；层数加深时输出方差剧烈波动，训练不稳定；
- 解决手段. 必须使用学习率 Warmup 预热，否则很容易崩。

2. Pre-norm（Llama 系列、现代大模型主流）

$$x + \text{Sublayer}(\text{Norm}(x))$$

- 流程. 先对输入 x 做 Norm，再送入 Attention / FFN 子层，最后做残差相加；
- 优点.
 1. 残差直通路不经过 Norm，反向传播时梯度直接沿 shortcut 回到底层，不用穿过归一化层；
 2. 对权重初始化鲁棒性更强，可以训练超深超大模型（70B、405B）；
 3. 不需要严苛的 warmup 策略。