

Subject: CS336 Assignment 1, Feed-Forward Network

Date: from 2026/8/1 to 2026/8/2

Contents

Feed-Forward Network (FFN)	1
-----------------------------------	----------

Feed-Forward Network (FFN)

为什么需要 FFN?

一个 Transformer Block 的工作模式可以总结为：**先交流，再计算**。

- **交流阶段 (Attention)**。Token 之间互相“对眼神”；通过 MHA，每个词把全句和自己最相关的特征都抓取过来，存在自己的向量里。但这步只是搬运，并没有产生质变；
- **计算阶段 (FFN)**。每个词回到自己的位置上，利用 FFN 这一层对刚抓到的素材进行深度消化；它通过高维投影和非线性变换，把零散的上下文信号合并成更高阶的语义概念。

SwiGLU 的数学逻辑

传统 FFN (GPT-2 时代) 使用 $\text{Linear} \rightarrow \text{ReLU} \rightarrow \text{Linear}$ ；现代模型则使用 SwiGLU，它通过“门控机制”提供了更强的表达能力。

1. 核心公式

$$\text{FFN}_{\text{SwiGLU}}(x) = (\text{SiLU}(xW_1) \otimes xW_3)W_2$$

把计算过程拆解为三条路径：

1. **门控分支 (Gate Path)**。输入 x 经过 W_1 升维，随后应用 SiLU 激活函数，它决定了哪些信息是重要的；
2. **信号分支 (Signal Path)**。输入 x 经过 W_3 升维，它提供了实际要处理的内容；
3. **融合与降维**。将两条路径的结果逐元素相乘 ($\otimes$)，最后经过 W_2 映射回原始维度 d_{model} 。

2. 激活函数：SiLU (Swish)




Figure 1: SiLU 与 ReLU、Identity 的对比。

$$\text{SiLU}(x) = x \cdot \sigma(x) = \frac{x}{1 + e^{-x}}$$

相比 ReLU，SiLU 在 0 点附近更加平滑，且允许微弱的负值通过，这有助于深层网络中的梯度流动。

参数规模与 8/3 维度准则

- **传统 FFN.** 使用 2 个矩阵 ($d_{model} \rightarrow 4d_{model}$ 与 $4d_{model} \rightarrow d_{model}$)，总参数量 $\approx 8d_{model}^2$ ；
- **SwiGLU FFN.** 使用 3 个矩阵 (W_1, W_3 升维, W_2 降维)；
- **如何保持参数量对齐?** 为了让 SwiGLU 的总参数量与传统 FFN 持平，不再使用 4 倍升维，而是把中间维度 d_{ff} 设为 d_{model} 的 **8/3 倍**；
- **硬件对齐要求.** 为了优化 GPU 计算效率， d_{ff} 通常需要向上取整为 **64 的倍数**。

	矩阵数	中间维度 d_{ff}	总参数量
传统 FFN	2	$4d_{model}$	$\approx 8d_{model}^2$
SwiGLU FFN	3	$\frac{8}{3}d_{model}$	$\approx 8d_{model}^2$