

Subject: CS336 Assignment 1, RMSNorm

Date: from 2026/8/3 to 2026/8/4

Contents

Normalization: RMSNorm	1
------------------------	---

Normalization: RMSNorm

LayerNorm

1. 核心定义：针对 Token 的“精准调控” LayerNorm 的目标是把神经网络每一层输出的数值强行“拉回”到标准范围。

- 作用对象. 把每一个 Token 看作独立个体；在 $[B, S, D]$ 张量中，它针对的是 D （特征维度）；
- 计算频率. 在一个 Batch 中独立执行 $B \times S$ 次归一化计算。

2. 深度价值：为什么大模型离不开它？

维度一：训练更稳定

- 现状. LLM 包含上百层 Block；如果没有归一化，信号就像“传声筒”游戏；
- 蝴蝶效应. 初始音量 1，若每层增加 0.1，100 层后 $1.1^{100} \approx 13780$ ，信号会迅速爆炸（NaN）或消失（0），导致梯度崩溃；
- LayerNorm 方案. 在每一层出口安装“自动调音器”，强行把输出拉回均值 0、方差 1，确保无论模型多深能量始终恒定。

维度二：训练更快

- 现状（崎岖地形）。若特征维度尺度不一（如维度 A 范围 0–1000，维度 B 范围 0–1），Loss 空间会形成极度扁平的“深谷”，梯度下降极易震荡，迫使使用极小的学习率；
- LayerNorm 方案（平缓盆地）。通过对齐所有维度的尺度，把地形重塑为圆形的“大盆地”；
- 直觉. 盆地中坡度均匀，可以放心使用更大的学习率，训练效率显著提升。

3. 数学逻辑：中心化 + 缩放 LayerNorm 对向量 x 的处理分为两个标准步骤：

1. 中心化（Centering）。算出均值 μ ，让向量所有元素减去它，结果是把向量的中轴线对齐到 0；
2. 缩放（Scaling）。算出标准差 σ ，让向量除以它，结果是把分布宽度（方差）变成 1。

最终公式：

$$\text{LayerNorm}(x) = \frac{x - \mathbb{E}[x]}{\sqrt{\text{Var}[x] + \epsilon}} \cdot \gamma + \beta \quad \text{Std}[x] = \sqrt{\text{Var}[x] + \epsilon} = \sqrt{\frac{1}{d} \sum_{i=1}^d (x_i - \mu)^2 + \epsilon}$$

其中 ϵ 是一个极小的常数（防止除以 0）； γ 与 β 是可学习参数，允许模型在必要时打破“均值 0 / 方差 1”的束缚，自主调节信号的幅度和偏移。

RMSNorm

1. 公式 对于一个 d 维的激活向量 a ，归一化过程为

$$\text{RMSNorm}(a_i) = \frac{a_i}{\text{RMS}(a)} \cdot g_i \quad \text{RMS}(a) = \sqrt{\frac{1}{d} \sum_{j=1}^d a_j^2 + \epsilon}$$

- ϵ ：一个微小的常数（如 10^{-5} ），防止除以 0；
- g ：一个可学习的增益参数（Gain），维度与隐藏层 d_{model} 一致。

2. 具象化数值案例 假设 $d = 2$ （特征维为 2），输入向量为 $[3, 4]$ ，增益参数 g 初始为 $[1, 1]$ ：

1. 平方均值 (Mean Square) . $(3^2 + 4^2)/2 = 12.5$;
2. 开方 (Root) . $\sqrt{12.5} \approx 3.53$;
3. 归一化. $3/3.53 = 0.85$, $4/3.53 = 1.13$;
4. 输出. 结果为 $[0.85, 1.13]$.

为什么从 LayerNorm 转向 RMSNorm

传统的 LayerNorm 包含两个步骤:

1. 平移 (Centering) . 减去均值 μ , 使数据中心对齐到 0;
2. 缩放 (Scaling) . 除以标准差 σ , 使数据的方差对齐到 1.

RMSNorm 的核心观察. 研究表明, LayerNorm 的“减去均值”操作对模型性能的贡献微乎其微, 反而增加了额外的计算开销.

RMSNorm 的优势.

- **计算更少.** 不计算均值, 只计算均方根;
- **更稳定.** 在保持相同性能的前提下, 计算效率提升约 10%–40%, 且在深层网络中表现优异.

对比: LayerNorm vs RMSNorm

特性	LayerNorm	RMSNorm
数学公式	$\frac{x - \mu}{\sigma} \cdot \gamma + \beta$	$\frac{x}{\text{RMS}(x)} \cdot \gamma$
均值处理	有, 减去 μ 把分布中心移到 0	无, 只控制振幅
学习参数	两个: weight (γ) 和 bias (β)	一个: weight (γ)
计算开销	较高 (需计算均值和方差)	较低 (只需计算均方根)
工业应用	GPT-2、BERT、早期 Transformer	Llama 2/3、Mistral、现代大模型标配