

Subject: CS336 Assignment 1, Cross-Entropy Loss

Date: from 2026/8/5 to 2026/8/6

Contents

Cross-Entropy Loss	1
---------------------------	----------

Cross-Entropy Loss

谁与谁的差距？（输入对齐）

在语言模型任务中，损失函数衡量的是模型对“下一个词”预测的准确度。

- **模型输出（Logits）** o . 形状为 $[\text{Batch}, \text{SeqLen}, \text{VocabSize}]$ ，代表模型认为词表中每个词作为下一个词的“能量分值”；注意此时它还没经过 **Softmax**，数值范围可能很大；
- **真实标签（Target）** y . 形状为 $[\text{Batch}, \text{SeqLen}]$ ，存储的是标准答案在词表中的索引 ID.

核心逻辑. 交叉熵的目标是让正确 ID 对应的 Logits 分值尽可能高，而让其他无关词的分值尽可能低.

从概率定义到工程公式

1. 原始定义（Softmax + Negative Log Likelihood） 对某个位置的输出 o 和正确索引 y ，损失 ℓ 的标准定义为

$$\ell = -\log(\text{Softmax}(o)_y) = -\log\left(\frac{\exp(o_y)}{\sum_j \exp(o_j)}\right)$$

2. 工程化拆解（对数运算律） 利用 $\log(a/b) = \log a - \log b$ 把公式展开：

$$\ell = -\left(\log(\exp(o_y)) - \log \sum_j \exp(o_j)\right) = \underbrace{\log\left(\sum_j \exp(o_j)\right)}_{\text{LogSumExp 项}} - o_y$$

这个公式在工程上更受欢迎，因为它减少了除法操作，并把复杂的比值转化成了减法.

数值稳定性：为什么要用 Log-Sum-Exp 技巧？

在训练几百亿参数的大模型时，Logits 的数值往往会失控，直接计算 $\exp(o_j)$ 非常危险：

- **上溢（Overflow）.** 单精度浮点数（FP32）能表示的最大值约为 3.4×10^{38} ；如果 Logits 中出现一个 89， $\exp(89)$ 就会超过这个上限，结果直接变成 **Inf**，随后导致整个 Loss 变成 **NaN**.
- **对策：减去最大值 M .** 利用恒等式

$$\log \sum_j \exp(o_j) = M + \log \sum_j \exp(o_j - M), \quad M = \max(o)$$

把指数运算的输入整体平移，从而避免上溢.

示例

假设有一个极小的场景：

- Batch Size $B = 1$ （一个句子）；
- Sequence Length $S = 2$ （两个单词）；
- Vocab Size $V = 3$ （词表只有 A、B、C 三个词）。

1. 输入数据 模型输出的原始分值 Logits（shape (1, 2, 3)）与真实标签 Targets（shape (1, 2)）：

	位置 1	位置 2
Logits	[2.0, 1.0, 0.1]	[0.5, 3.0, 1.2]
最看好的词	A	B
Target	0 (= A)	1 (= B)

2. 步骤拆解

Step 1: 计算最大值 M （数值稳定） 位置 1 最大值 $m_1 = 2.0$ ，位置 2 最大值 $m_2 = 3.0$ ； $M = [[2.0], [3.0]]$ ，形状为 (1, 2, 1)。

Step 2: 提取目标位置分值 o_y （使用 **gather**） 位置 1 提取索引 0 的值 $\rightarrow 2.0$ ；位置 2 提取索引 1 的值 $\rightarrow 3.0$ ； $\text{target_logits} = [2.0, 3.0]$ 。

Step 3: 计算 Log-Sum-Exp（LSE） 以位置 1 为例：

1. 减去最大值： $[2.0 - 2.0, 1.0 - 2.0, 0.1 - 2.0] = [0, -1.0, -1.9]$ ；
2. 取指数并求和： $e^0 + e^{-1.0} + e^{-1.9} \approx 1 + 0.36 + 0.15 = 1.51$ ；
3. 取对数并加回 M ： $\log(1.51) + 2.0 \approx 0.41 + 2.0 = 2.41$ 。

同理可得位置 2 的 $\text{LSE}_2 \approx 3.22$ 。

Step 4: 计算 Token Loss ($\text{LSE} - o_y$) 位置 1 损失 $2.41 - 2.0 = 0.41$ ；位置 2 损失 $3.22 - 3.0 = 0.22$ 。

Step 5: 求全批次平均（Mean） 最终

$$\text{Loss} = \frac{0.41 + 0.22}{2} = 0.315$$