

Subject: CS336 Assignment 1, Cosine Learning-Rate Schedule

Date: from 2026/8/12 to 2026/8/15

Contents

Cosine Learning-Rate Schedule	1
--------------------------------------	----------

Cosine Learning-Rate Schedule

为什么学习率需要“调度”？

如果我们在整个训练过程中使用固定的学习率，模型会面临两个困境：

1. **起步难**. 训练初期模型参数是随机初始化的，如果学习率过大，不稳定的梯度会瞬间破坏模型，导致 Loss 爆炸；
2. **收敛难**. 训练后期模型已经接近最优解，如果学习率依然很大，优化器会在“山谷”底部反复横跳，无法进入最精确的低点。

解决方案.

- **Warmup** (预热). 起步时，学习率从 0 线性增加到最大值；
- **Cosine Decay** (余弦衰减). 到达顶点后，学习率按照余弦曲线平滑下降。

算法阶段拆解

把学习率的演变分为三个阶段：

1. 预热阶段 (Warm-up)

- **逻辑**. 像飞机起飞，在跑道上逐渐加速；
- **公式**. $\alpha_t = \alpha_{max} \cdot \frac{t}{T_{warmup}}$ ；
- **物理意义**. 让模型在不稳定的训练初期，以极小的步长“试探”方向，逐渐过渡到高速训练。

2. 余弦退火阶段 (Cosine Annealing)

- **逻辑**. 像平滑降落，优雅地进入最优区域；
- **公式核心**. 利用 $\cos$ 函数在 $[0, \pi]$ 区间从 1 降到 -1 的特性，通过 $\frac{1}{2}(1 + \cos(\dots))$ 把波动范围映射到 $[1, 0]$ ：

$$\alpha_t = \alpha_{min} + \frac{1}{2}(\alpha_{max} - \alpha_{min}) \left(1 + \cos\left(\pi \cdot \frac{t - T_{warmup}}{T_{total} - T_{warmup}}\right) \right)$$

- **优势**. 相比于阶梯式下降，余弦退火没有突然的数值跳变，梯度更加平滑。

3. 退火后阶段 (Post-annealing)

- **逻辑**. 保持最低速滑行；
- **公式**. $\alpha_t = \alpha_{min}$ ；
- **物理意义**. 当预定的训练周期结束、如果还需要继续训练，则维持一个极小的学习率进行微调。

阶段	公式
预热 Warm-up	$\alpha_{max} \cdot \frac{t}{T_{warmup}}$
余弦退火 Cosine Annealing	$\alpha_{min} + \frac{1}{2}(\alpha_{max} - \alpha_{min})(1 + \cos(\dots))$
退火后 Post-annealing	α_{min}

其他学习率调度策略

延伸阅读: <https://zhuanlan.zhihu.com/p/14402471296>