

Subject: CS336 Assignment 1, Gradient Clipping

Date: from 2026/8/16 to 2026/8/17

Contents

Gradient Clipping	1
--------------------------	----------

Gradient Clipping

背景：为什么需要梯度裁剪

在训练深层 Transformer 模型时，由于网络层数多且包含复杂的非线性变换，模型经常会遇到梯度爆炸的问题。本节实现梯度裁剪，确保模型在不稳定的训练初期或遇到极端数据时不会崩溃。

梯度裁剪作用

在每次反向传播之后、优化器步进 (Step) 之前，检查所有参数梯度的总长度 (Global Norm)。如果总长度超过了安全阈值 M ，就把步子按比例收回来，确保步长落在安全范围内，同时保持前进的方向不变。

数学逻辑：全局 L2 范数

梯度裁剪的核心是计算全局 L2 范数。我们把模型中所有层的梯度拼接成一个巨大的向量 g ，然后计算它的欧几里得长度：

$$\|g\|_2 = \sqrt{\sum_{p \in \theta} \|g_p\|_2^2}$$

如果 $\|g\|_2 > M$ ，则对所有梯度进行等比例缩放：

$$g_{new} = g_{old} \times \frac{M}{\|g\|_2 + \epsilon}$$

其中 ϵ 是一个极小的常数，防止分母为 0。缩放只改变步长的大小、不改变方向。

实现。对应到工程代码：

```
total_norm = torch.sqrt(sum(p.grad.norm()**2 for p in params))
if total_norm > M:
    scale = M / (total_norm + eps)
    for p in params:
        p.grad.mul_(scale)
```